

二、LLM 训练阶段

一、预训练: Pre-Traning

二、监督微调: Supervised Fine-Tuning(SFT)

三、奖励模型训练: Reward Model Training(RM)

四、强化学习优化: RL

五、垂直领域的 SFT

一、预训练: Pre-Traning

目标: 让模型学习通用的语言知识, 具备基础的语言理解和生成能力;

技术特点:

- 使用海量无标注文本数据(互联网数据);
- 模型结构以"自监督学习"结构为主:
 - 自回归预测: 给定文本序列, 预测下一个单词 token, 比如: GPT 系列等解码器结构;
 - 生成模型结构: 给定编码器输入, 预测解码器输出, 比如: T5 之类;

输出模型特点: 具备基本的语法、语义和基本逻辑, 单缺乏遵循具体指令或者完成某种特定任务的能力。

二、监督微调: Supervised Fine-Tuning(SFT)

目标: 让模型学会遵循人类指令, 将通用语言能力转换为执行具体任务的能力;

技术特点:

- 基于预训练模型进行模型参数微调;
- 使用人工标注的高质量"指令-响应"数据进行有监督训练, 主要包括两个数据格式: 单一任务指令、多轮对话数据;
- 采用有监督的方式, 通过梯度下降等方式训练模型;

输出模型特点: 一个满足指令遵循, 能够理解并执行不同指令的模型, 但是可能存在安全性、一致性等方面的问题;

三、奖励模型训练: Reward Model Training(RM)

目标: 训练一个具有"评价标注"的分类模型, 能够量化模型回答的质量;

技术特点:

- 一般基于预训练模型进行结构参数迁移微调训练;
- 高质量人工标注"人类偏好数据": 针对同一个问题的多个回答, 由人工进行排序(那个回答更好);

- 有监督训练：针对输入的"问题 + 答案"，输出一个类似的"质量评分"，拟合人类对结果偏好的盘点；

输出模型特点：一个具备类似人类偏好的，具有判断回答好坏的分类模型；

四、强化学习优化: RL

目标：基于奖励模型的反馈，进一步优化模型，使微调后的模型更满足人类的偏好价值；

技术特点：

- 以 SFT 微调后的模型作为初始"策略"模型，不断迭代执行：策略模型生成回答，奖励模型进行打分，反馈微调策略模型参数；
- 使用强化学习相关算法：PPO 等；调整模型参数，最大化奖励分数；
- 核心是让模型主动学习如何生成更高质量的回答，而不是单纯基于数据的模仿；
- PS:最终模型效果受奖励模型的影响非常重；

输出模型特点：一个对齐人类偏好的模型，满足安全性、一致性等各个方面的要求；

PS: 本质上为了让模型能够理解在多个回答中，那种回答更好，也可以直接采用不依赖奖励模型的直接训练方式，直接从人类偏好数据中进行学习，将偏好进行训练目标转换 — **模型生成更好回答 A 的概率高于生成较差回答 B 的概率**，比如：DPO 算法等。

五、垂直领域的 SFT

目标：让模型适应具体行业或者业务场景的需求。

常见方式：

- 领域微调：使用行业专业领域数据进一步微调，从而增强领域知识；
- 提示工程微调：设计采用特定的模板，微调引导模型的输出符合期望输出；
- 工具调用微调：训练模型调用外部工具的能力，从而扩展能力边界(一般也是通过提示词模型来实现)；

PS：一般情况下，如果需要微调，我们都是针对特定领域的数据进行模型微调；