




NLP项目

扩展CRF条件随机场

Softmax回顾

⌚ Softmax回归是logistic回归的一般化，适用于K分类的问题。




Softmax回顾

$$\begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix} = \text{softmax} \left(\begin{bmatrix} W_{1,1}x_1 + W_{1,2}x_2 + W_{1,3}x_3 + b_1 \\ W_{2,1}x_1 + W_{2,2}x_2 + W_{2,3}x_3 + b_2 \\ W_{3,1}x_1 + W_{3,2}x_2 + W_{3,3}x_3 + b_3 \end{bmatrix} \right)$$

$$\begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix} = \text{softmax} \left(\begin{bmatrix} W_{1,1} & W_{1,2} & W_{1,3} \\ W_{2,1} & W_{2,2} & W_{2,3} \\ W_{3,1} & W_{3,2} & W_{3,3} \end{bmatrix} \cdot \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} + \begin{bmatrix} b_1 \\ b_2 \\ b_3 \end{bmatrix} \right)$$

HMM回顾



- ✦ HMM即**隐马尔可夫模型**，它是处理序列问题的统计学模型，描述的过程为：**由隐马尔科夫链随机生成不可观测的状态随机序列，然后各个状态分别生成一个观测，从而产生观测随机序列。**
- ✦ 在这个过程中，不可观测的序列称为状态序列(state sequence), 由此产生的序列称为观测序列(observation sequence)。

HMM回顾

- ⌚ 隐马尔可夫模型 λ 可以由一下三个模型参数组成:
 - ⌚ 初始概率分布: 即初始的隐含状态概率分布, 记为 π ;
 - ⌚ 状态转移概率分布(转移矩阵): 即隐含状态之间的转移概率分布, 记为 A ;
 - ⌚ 观测概率分布(发射矩阵): 即由隐含状态生成观测状态的概率分布, 记为 B 。

$$\lambda = (A, B, \pi)$$


HMM回顾

⌚ 隐马尔可夫的三个基本问题：

⌚ 概率计算问题

⌚ 模型学习问题

⌚ **解码问题**



HMM回顾

⌚ Viterbi算法：用动态规划的思路求解HMM预测问题，求出概率最大的“路径”，每条“路径”对应一个状态序列。

$$\delta_t(i) = \max_{s_1, s_2, \dots, s_{t-1}} p(s_t = i, s_1, s_2, \dots, s_{t-1}, o_t, o_{t-1}, \dots, o_1; \lambda)$$

$$\delta_t(i) = \max_{1 \leq j \leq n} (\delta_{t-1}(j) a_{ji}) b_{io_t}$$

HMM案例回顾-Viterbi

- 在给定参数 π 、 A 、 B 的时候，得到观测序列为“白黑白白黑”，求出最优的隐藏状态序列。

$$\pi = \begin{pmatrix} 0.2 \\ 0.5 \\ 0.3 \end{pmatrix}$$

$$A = \begin{bmatrix} 0.5 & 0.4 & 0.1 \\ 0.2 & 0.2 & 0.6 \\ 0.2 & 0.5 & 0.3 \end{bmatrix}$$

$$B = \begin{bmatrix} 0.4 & 0.6 \\ 0.8 & 0.2 \\ 0.5 & 0.5 \end{bmatrix}$$

HMM案例回顾-Viterbi

$$A = \begin{bmatrix} 0.5 & 0.4 & 0.1 \\ 0.2 & 0.2 & 0.6 \\ 0.2 & 0.5 & 0.3 \end{bmatrix} \quad B = \begin{bmatrix} 0.4 & 0.6 \\ 0.8 & 0.2 \\ 0.5 & 0.5 \end{bmatrix} \quad \pi = \begin{pmatrix} 0.2 \\ 0.5 \\ 0.3 \end{pmatrix}$$

$$\delta_1(i) = \pi_i b_{iq_1} = \pi_i b_{i\text{白}}$$
$$\begin{aligned} \delta_1(1) &= 0.08 \\ \delta_1(2) &= 0.4 \\ \delta_1(3) &= 0.15 \end{aligned}$$

$$\delta_2(i) = \max_{1 \leq j \leq 3} (\delta_1(j) a_{ji}) b_{iq_2} = \max_{1 \leq j \leq 3} (\delta_1(j) a_{ji}) b_{i\text{黑}}$$

$$\delta_2(1) = \max\{0.08 * 0.5, 0.4 * 0.2, 0.15 * 0.2\} * 0.6 = 0.048$$

$$\delta_2(2) = \max\{0.08 * 0.4, 0.4 * 0.2, 0.15 * 0.5\} * 0.2 = 0.016$$

$$\delta_2(3) = \max\{0.08 * 0.1, 0.4 * 0.6, 0.15 * 0.3\} * 0.5 = 0.12$$

HMM案例回顾-Viterbi

$$A = \begin{bmatrix} 0.5 & 0.4 & 0.1 \\ 0.2 & 0.2 & 0.6 \\ 0.2 & 0.5 & 0.3 \end{bmatrix} \quad B = \begin{bmatrix} 0.4 & 0.6 \\ 0.8 & 0.2 \\ 0.5 & 0.5 \end{bmatrix} \quad \pi = \begin{pmatrix} 0.2 \\ 0.5 \\ 0.3 \end{pmatrix}$$

$$\delta_1(1) = 0.08$$

$$\delta_2(1) = 0.048$$

$$\delta_1(2) = 0.4$$

$$\delta_2(2) = 0.016$$

$$\delta_1(3) = 0.15$$

$$\delta_2(3) = 0.12$$

$$\delta_3(i) = \max_{1 \leq j \leq 3} (\delta_2(j) a_{ji}) b_{iq_3} = \max_{1 \leq j \leq 3} (\delta_2(j) a_{ji}) b_{i\text{白}}$$

$$\delta_3(1) = \max\{0.048 * 0.5, 0.016 * 0.2, 0.12 * 0.2\} * 0.4 = 0.024 * 0.4 = 0.0096$$

$$\delta_3(2) = \max\{0.048 * 0.4, 0.016 * 0.2, 0.12 * 0.5\} * 0.8 = 0.06 * 0.8 = 0.048$$

$$\delta_3(3) = \max\{0.048 * 0.1, 0.016 * 0.6, 0.12 * 0.3\} * 0.5 = 0.036 * 0.5 = 0.018$$

HMM案例回顾-Viterbi

$$A = \begin{bmatrix} 0.5 & 0.4 & 0.1 \\ 0.2 & 0.2 & 0.6 \\ 0.2 & 0.5 & 0.3 \end{bmatrix} \quad B = \begin{bmatrix} 0.4 & 0.6 \\ 0.8 & 0.2 \\ 0.5 & 0.5 \end{bmatrix} \quad \pi = \begin{pmatrix} 0.2 \\ 0.5 \\ 0.3 \end{pmatrix}$$

$$\begin{array}{lll} \delta_1(1) = 0.08 & \delta_2(1) = 0.048 & \delta_3(1) = 0.0096 \\ \delta_1(2) = 0.4 & \delta_2(2) = 0.016 & \delta_3(2) = 0.048 \\ \delta_1(3) = 0.15 & \delta_2(3) = 0.12 & \delta_3(3) = 0.018 \end{array}$$

$$\delta_4(i) = \max_{1 \leq j \leq 3} (\delta_3(j) a_{ji}) b_{iq_4} = \max_{1 \leq j \leq 3} (\delta_3(j) a_{ji}) b_{i\text{白}}$$

$$\delta_4(1) = \max\{0.0096 * 0.5, 0.048 * 0.2, 0.018 * 0.2\} * 0.4 = 0.0096 * 0.4 = 0.0096$$

$$\delta_4(2) = \max\{0.0096 * 0.4, 0.048 * 0.2, 0.018 * 0.5\} * 0.8 = 0.0096 * 0.8 = 0.00768$$

$$\delta_4(3) = \max\{0.0096 * 0.1, 0.048 * 0.6, 0.018 * 0.3\} * 0.5 = 0.0288 * 0.5 = 0.0144$$

HMM案例回顾-Viterbi

$$A = \begin{bmatrix} 0.5 & 0.4 & 0.1 \\ 0.2 & 0.2 & 0.6 \\ 0.2 & 0.5 & 0.3 \end{bmatrix} \quad B = \begin{bmatrix} 0.4 & 0.6 \\ 0.8 & 0.2 \\ 0.5 & 0.5 \end{bmatrix} \quad \pi = \begin{pmatrix} 0.2 \\ 0.5 \\ 0.3 \end{pmatrix}$$

$$\begin{array}{llll} \delta_1(1) = 0.08 & \delta_2(1) = 0.048 & \delta_3(1) = 0.0096 & \delta_4(1) = 0.00384 \\ \delta_1(2) = 0.4 & \delta_2(2) = 0.016 & \delta_3(2) = 0.048 & \delta_4(2) = 0.00768 \\ \delta_1(3) = 0.15 & \delta_2(3) = 0.12 & \delta_3(3) = 0.018 & \delta_4(3) = 0.0144 \end{array}$$

$$\delta_5(i) = \max_{1 \leq j \leq 3} (\delta_4(j) a_{ji}) b_{iq_5} = \max_{1 \leq j \leq 3} (\delta_4(j) a_{ji}) b_{i_{\text{黑}}}$$

$$\delta_5(1) = \max\{0.00384 * 0.5, 0.00768 * 0.2, 0.0144 * 0.2\} * 0.6 = 0.00288 * 0.6 = 0.001728$$

$$\delta_5(2) = \max\{0.00384 * 0.4, 0.00768 * 0.2, 0.0144 * 0.5\} * 0.2 = 0.0072 * 0.2 = 0.00144$$

$$\delta_5(3) = \max\{0.00384 * 0.1, 0.00768 * 0.6, 0.0144 * 0.3\} * 0.5 = 0.004608 * 0.5 = 0.002304$$


HMM案例回顾-Viterbi

$$\begin{array}{ll}\delta_1(1) = 0.08 & \delta_2(1) = 0.048 \\ \delta_1(2) = 0.4 & \delta_2(2) = 0.016 \\ \delta_1(3) = 0.15 & \delta_2(3) = 0.12\end{array}$$

$$\begin{array}{lll}\delta_3(1) = 0.0096 & \delta_4(1) = 0.00384 & \delta_5(1) = 0.001728 \\ \delta_3(2) = 0.048 & \delta_4(2) = 0.00768 & \delta_5(2) = 0.00144 \\ \delta_3(3) = 0.018 & \delta_4(3) = 0.0144 & \delta_5(3) = 0.002304\end{array}$$

- 最终盒子序列为: (2, 3, 2, 2, 3), 备注: 盒子序号从1开始

HMM案例回顾-Viterbi



HMM回顾

⌚ HMM假设**当前状态仅和前一个状态有关**，也就是具有一阶马尔可夫性质，但是在很多场景中，模型不仅仅需要考虑前一个状态的信息，也可能需要后一个状态的信息，因此需要模型提出更多的假设条件，也就是引入**图模型**
(当前状态和相连状态都有关)+条件模型(当前状态和观测值有关)=条件随机场。比如：“ 我爱中国”，结构更加复杂，信息更加丰富。


随机场

- ⌚ 随机场是由若干个位置组成的整体，当给每一个位置中按照某种分布随机赋予一个值之后，其全体就叫做随机场。假如我们有一个十个词形成的句子需要做词性标注。这十个词每个词的词性可以在我们已知的词性集合（名词，动词...）中去选择。当我们为每个词选择完词性后，这就形成了一个随机场。

⌚ 现在有小明同学一天内不同时段的照片，从小明起床到睡觉各个时间段都有。现在的任务是对这些照片进行分类。比如有的照片是吃饭，那就给它打上吃饭的标签；有的照片是跑步时拍的，那就打上跑步的标签；有的照片是开会时拍的，那就打上开会的标签。问题来了，如何进行标签给定呢？

CRF


- ⌚ 方式一：一个简单直观的办法就是，不管这些照片之间的时间顺序，想办法训练出一个多元分类器。就是用一些打好标签的照片作为训练数据，训练出一个模型，直接根据照片的特征来分类。例如，如果照片是早上6:00拍的，且画面是黑暗的，那就给它打上睡觉的标签；如果照片上有车，那就给它打上开车的标签。



⌚ 问题：由于我们忽略了这些照片之间的时间顺序这一重要信息，我们的分类器会有缺陷的。举个例子，假如有一张小明闭着嘴的照片，怎么分类？显然难以直接判断，需要参考闭嘴之前的照片，如果之前的照片显示小明在吃饭，那这个闭嘴的照片很可能是小明在咀嚼食物准备下咽，可以给它打上吃饭的标签；如果之前的照片显示小明在唱歌，那这个闭嘴的照片很可能是小明唱歌瞬间的抓拍，可以给它打上唱歌的标签。


CRF

- ⌚ 方式二：为了让我们的分类器能够有更好的表现，在为一张照片分类时，我们必须将与它相邻的照片的标签信息考虑进来。





CRF

⌚ 条件随机场(Conditional Random Fields, 简称CRF)给定一组输入序列条件下另一组输出序列的条件概率分布模型，在自然语言处理中得到了广泛应用。最常见的形式为：**线性链(Linear Chain) CRF**。




CRF

- ⌚ 条件随机场(Conditional Random Fields, 简称CRF)是MRF的特例, 在CRF中, 假设马尔可夫随机场中只有X和Y两个变量, X一般是给定的, 而Y是当X给定的条件下模型的输出。




CRF

⌚ 设 $X=(X_1, X_2, \dots, X_n)$ 和 $Y=(Y_1, Y_2, \dots, Y_n)$ 均为线性链表示的随机变量序列，在给定随机变量序列 X 的情况下，随机变量 Y 的条件概率分布 $P(Y|X)$ 就是条件随机场，即满足**马尔可夫性质**。



$$P(Y_i | X, Y_1, Y_2, \dots, Y_n) = P(Y_i | X, Y_{i-1}, Y_{i+1})$$


CRF



$$P(Y_i | X_i, Y_1, Y_2, \dots, Y_n) = P(Y_i | X_i, Y_{i-1}, Y_{i+1})$$

最简单的一个贝叶斯网络

$$P(a,b,c) = P(c \mid a,b)P(b \mid a)P(a)$$



贝叶斯网络判定条件独立-01

⌚ 在C给定的条件下，a和b被阻断(blocked)是独立的



⌚ 条件独立: tail - to -tail

$$P(a, b, c) = P(c)P(b | c)P(a | c)$$

$$\Rightarrow P(a, b, c) / P(c) = P(b | c)P(a | c)$$

$$\because p(a, b | c) = p(a, b, c) / p(c)$$


$$\therefore p(a, b | c) = p(a | c)p(b | c)$$



贝叶斯网络判定条件独立-02

⌚ 在C给定的条件下，a和b被阻断(blocked)是独立的

⌚ 条件独立: head- to -tail



$$P(a, b, c) = P(a)P(c | a)P(b | c)$$

$$p(a, b | c)$$

$$= p(a, b, c) / p(c)$$

$$= p(a) * p(c | a) * p(b | c) / p(c)$$

$$= p(a, c) * p(b | c) / p(c)$$

$$= p(a | c) * p(b | c)$$

贝叶斯网络判定条件独立-03



⌚ 在C未知的情况下，a和b被阻断(blocked)，是独立的

⌚ 条件独立：head - to - head

$$P(a, b, c) = P(a)P(b)P(c | a, b)$$

$$\sum_c P(a, b, c) = \sum_c P(a) * P(b) * P(c | a, b)$$

$$\Rightarrow P(a, b) = P(a) * P(b)$$



- ⌚ 在Linear CRF中，特征函数分为两类；第一类是定义在Y节点上的节点特征函数，这个特征函数只和当前节点有关。

$$s_l(y_i, x, i), l = 1, 2, \dots, L$$

i 是当前节点在序列中的位置

L 是节点特征函数总数

- ⌚ 第二类是定义在Y上下文的局部特征函数，这类特征函数只和当前节点+上一个节点有关。

$$t_k(y_{i-1}, y_i, x, i), k = 1, 2, \dots, K$$

K 是局部特征函数总个数

CRF

- ⌚ 无论是节点特征函数还是局部特征函数，它们的取值只能是0或者1。即满足特征条件或者不满足特征条件。同时，我们可以为每个特征函数赋予一个权值，用以表达我们对这个特征函数的信任度。从而得到Linear CRF的参数化形式如下：

$$p(y|x) = \frac{1}{Z(x)} e^{\sum_{i,k} \lambda_{k,i} t_k(y_{i-1}, y_i, x, i) + \sum_{i,l} \mu_{l,i} s_l(y_i, x, i)}$$

λ 是 t 的权重系数

μ 是 s 的权重系数

CRF

$$p(y|x) = \frac{1}{Z(x)} e^{\sum_{i,k} \lambda_{k,i} t_k(y_{i-1}, y_i, x, i) + \sum_{i,l} \mu_{l,i} s_l(y_i, x, i)}$$

$$Z(x) = \sum_y \exp\left(\sum_{i,k} \lambda_{k,i} t_k(y_{i-1}, y_i, x, i) + \sum_{i,l} \mu_{l,i} s_l(y_i, x, i)\right)$$

$$s_l(y_i, x, i), l = 1, 2, \dots, L$$

⌚ 假定Linear CRF在词性标注中的案例，简化词性类别: {1: 名词, 2: 动词};
假定输入三个词的语句 $X=(X_1, X_2, X_3)$ ，输出标记记为 $Y=(Y_1, Y_2, Y_3)$ ；假定通过模型训练最终得到如下内容：

t,k, λ	i=2	i=3
$y_{i-1}, y_i = 1, 1$	1, 0.6	0, 0.0
$y_{i-1}, y_i = 1, 2$	1, 1.0	1, 1.0
$y_{i-1}, y_i = 2, 1$	1, 1.0	1, 1.0
$y_{i-1}, y_i = 2, 2$	0, 0.0	1, 0.2

$$t_1(y_1 = 1, y_2 = 1, x, 2) = 1; \lambda_{1,2} = 0.6$$
$$t_2(y_{i-1} = 1, y_i = 2, x, i) = 1; \lambda_{2,2} = 1.0; \lambda_{2,3} = 1.0$$
$$t_3(y_{i-1} = 2, y_i = 1, x, i) = 1; \lambda_{3,2} = 1.0; \lambda_{3,3} = 1.0$$
$$t_4(y_2 = 2, y_3 = 2, x, 3) = 1; \lambda_{4,3} = 0.2$$

s,l, μ	i=1	i=2	i=3
$y_i = 1$	1, 1.0	1, 0.8	1, 0.8
$y_i = 2$	1, 0.5	1, 0.5	1, 0.5

$$s_1(y_i = 1, x, i) = 1; \mu_{1,1} = 1.0; \mu_{1,2} = 0.8; \mu_{1,3} = 0.8$$
$$s_2(y_i = 2, x, i) = 1; \mu_{2,1} = 0.5; \mu_{2,2} = 0.5; \mu_{2,3} = 0.5$$

CRF

s,μ	i=1	i=2	i=3
y_i = 1	1,1.0	1,0.8	1,0.8
y_i = 2	1,0.5	1,0.5	1,0.5

t,λ	i=2	i=3
y_{i-1},y_i = 1,1	1, 0.6	0
y_{i-1},y_i = 1,2	1, 1.0	1, 1.0
y_{i-1},y_i = 2,1	1, 1.0	1, 1.0
y_{i-1},y_i = 2,2	0	1, 0.2

🕒 求解标记为(1,2,2)的非规范概率值:

$$p(y|x) \propto \exp\left(\sum_{i,k} \lambda_{k,i} t_k(y_{i-1}, y_i, x, i) + \sum_{i,l} \mu_{l,i} s_l(y_i, x, i)\right)$$

$$p(y_1 = 1, y_2 = 2, y_3 = 2|x)$$

$$\propto \exp((1.0 * 1 + 0.2 * 1) + (1.0 * 1 + 0.5 * 1 + 0.5 * 1)) = \exp(3.2)$$

⌚ 为了便捷求解，将取值相同的当做一个特征函数，将式子转换为：

$$p(y|x) = \frac{1}{Z(x)} e^{\sum_{i,k} \lambda_k t_k(y_{i-1}, y_i, x, i) + \sum_{i,l} \mu_l s_l(y_i, x, i)}$$

CRF

$$f_k(y_{i-1}, y_i, x, i) = \begin{cases} t_k(y_{i-1}, y_i, x, i), & k = 1, 2, \dots, K_1 \\ s_l(y_i, x, i), & k = K_1 + l, l = 1, 2, \dots, K_2 \end{cases}$$

$$f_k(y, x) = \sum_i f_k(y_{i-1}, y_i, x, i)$$

$$w_k = \begin{cases} \lambda_k, & k = 1, 2, \dots, K_1 \\ \mu_l, & k = K_1 + l, l = 1, 2, \dots, K_2 \end{cases}$$

$$p(y|x) = \frac{1}{Z(x)} \exp\left(\sum_k w_k f_k(y, x)\right) \quad Z(x) = \sum_k \exp\left(\sum_k w_k f_k(y, x)\right)$$

CRF

⌚ 使用对数似然函数的相反数作为损失函数的值：

$$L(w) = \sum_{x,y} \bar{P}(x,y) \ln P_w(y|x)$$

先验分布概率

给定x的情况下
y的预测概率值

$$loss = -L(w)$$

CRF

$$p(y|x) = \frac{1}{Z(x)} \exp\left(\sum_k w_k f_k(y, x)\right) \quad Z(x) = \sum_k \exp\left(\sum_k w_k f_k(y, x)\right)$$

⌚ 化简损失函数的形式(方便使用梯度下降)

$$\begin{aligned} loss &= -\sum_{x,y} \bar{P}(x, y) \ln P_w(y|x) \\ &= \sum_{x,y} \bar{P}(x, y) \ln Z_w(x) - \sum_{x,y} \bar{P}(x, y) \sum_k w_k f_k(x, y) \\ &= \sum_x \bar{P}(x) \ln Z_w(x) - \sum_{x,y} \bar{P}(x, y) \sum_k w_k f_k(x, y) \\ &= \sum_x \bar{P}(x) \ln \left(\sum_y \exp \left(\sum_k w_k f_k(x, y) \right) \right) - \sum_{x,y} \bar{P}(x, y) \sum_k w_k f_k(x, y) \end{aligned}$$

- ⌚ 在损失函数中对w求导即可得到如下式子，也就表示可以使用梯度下降法进行优化操作。

$$\frac{\partial loss}{\partial w_k} = \sum_{x,y} \bar{P}(x) P_{w_k}(y|x) f_k(x,y) - \sum_{x,y} \bar{P}(x,y) f_k(x,y)$$

CRF

$$p(y|x) = \frac{1}{Z(x)} \exp\left(\sum_k w_k f_k(y, x)\right)$$

⌚ 类似HMM的维特比算法，在CRF中，预测问题也是通过输入序列X，求解P(Y|X)对应的概率最大的序列Y。

$$\delta_i(l) = \max_{1 \leq j \leq m} \left\{ \delta_{i-1}(j) + \sum_{k=1}^K w_k f_k(y_{i-1} = j, y_i = l, x, i) \right\}$$

$$y_n^* = \arg \max_{1 \leq j \leq m} \delta_n(j)$$

$$\delta_1(l) = \sum_{k=1}^K w_k f_k(y_0 = start, y_1 = l, x, 1)$$

⌚ 假定Linear CRF在词性标注中的案例，简化词性类别: {1: 名词, 2: 动词};
假定输入三个词的语句X=(X1, X2, X3)，输出标记记为Y=(Y1, Y2, Y3); 求解最有可能的序列。

t,λ	i=2	i=3
y_i-1,y_i = 1,1	1, 0.6	0
y_i-1,y_i = 1,2	1, 1.0	1, 1.0
y_i-1,y_i = 2,1	1, 1.0	1, 1.0
y_i-1,y_i = 2,2	0	1, 0.2

s,μ	i=1	i=2	i=3
y_i = 1	1,1.0	1,0.8	1,0.8
y_i = 2	1,0.5	1,0.5	1,0.5

$t_1(y_1 = 1, y_2 = 1, x, 2) = 1; \lambda_{1,2} = 0.6$
 $t_2(y_{i-1} = 1, y_i = 2, x, i) = 1; \lambda_2 = 1.0; i = 2, 3$
 $t_3(y_{i-1} = 2, y_i = 1, x, i) = 1; \lambda_3 = 1.0; i = 2, 3$
 $t_4(y_2 = 2, y_3 = 2, x, 3) = 1; \lambda_4 = 0.2$

$s_1(y_1 = 1, x, 1) = 1; \mu_1 = 1.0$
 $s_2(y_i = 2, x, i) = 1; \mu_2 = 0.5; i = 1, 2, 3$
 $s_3(y_i = 1, x, i) = 1; \mu_1 = 0.8; i = 2, 3$

⌚ 第一个时刻的值:

$$\delta_1(l) = \sum_{k=1}^K w_k f_k(y_0 = start, y_1 = l, x, 1)$$

$$\delta_1(1) = 1.0 \quad \delta_1(2) = 0.5$$

⌚ 第二个时刻的值:

t,λ	i=2	i=3
y _{i-1} ,y _i = 1,1	1, 0.6	0
y _{i-1} ,y _i = 1,2	1, 1.0	1, 1.0
y _{i-1} ,y _i = 2,1	1, 1.0	1, 1.0
y _{i-1} ,y _i = 2,2	0	1, 0.2

s,μ	i=1	i=2	i=3
y _i = 1	1,1.0	1,0.8	1,0.8
y _i = 2	1,0.5	1,0.5	1,0.5

$$t_1(y_1 = 1, y_2 = 1, x, 2) = 1; \lambda_{1,2} = 0.6$$

$$t_2(y_{i-1} = 1, y_i = 2, x, i) = 1; \lambda_2 = 1.0; i = 2, 3$$

$$t_3(y_{i-1} = 2, y_i = 1, x, i) = 1; \lambda_3 = 1.0; i = 2, 3$$

$$t_4(y_2 = 2, y_3 = 2, x, 3) = 1; \lambda_4 = 0.2$$

$$s_1(y_1 = 1, x, 1) = 1; \mu_1 = 1.0$$

$$s_2(y_i = 2, x, i) = 1; \mu_2 = 0.5; i = 1, 2, 3$$

$$s_3(y_i = 1, x, i) = 1; \mu_1 = 0.8; i = 2, 3$$

$$\delta_2(l) = \arg \max_{1 \leq j \leq 2} \left(\delta_1(j) + \sum_{k=1}^K w_k f_k(y_1 = j, y_2 = l, x, 2) \right)$$

$$\delta_2(1) = \arg \max_{1 \leq j \leq 2} (1.0 + (0.6 + 1.0 + 0.8), 0.5 + (1.0 + 0.5 + 0.8)) = 3.4$$

$$\delta_2(2) = \arg \max_{1 \leq j \leq 2} (1.0 + (1.0 + 1.0 + 0.5), 0.5 + (0 + 0.5 + 0.5)) = 3.5$$

⌚ 第三个时刻的值:

t,λ	i=2	i=3
y _{i-1} ,y _i = 1,1	1, 0.6	0
y _{i-1} ,y _i = 1,2	1, 1.0	1, 1.0
y _{i-1} ,y _i = 2,1	1, 1.0	1, 1.0
y _{i-1} ,y _i = 2,2	0	1, 0.2

s,μ	i=1	i=2	i=3
y _i = 1	1,1.0	1,0.8	1,0.8
y _i = 2	1,0.5	1,0.5	1,0.5

$$t_1(y_1 = 1, y_2 = 1, x, 2) = 1; \lambda_{1,2} = 0.6$$

$$t_2(y_{i-1} = 1, y_i = 2, x, i) = 1; \lambda_2 = 1.0; i = 2, 3$$

$$t_3(y_{i-1} = 2, y_i = 1, x, i) = 1; \lambda_3 = 1.0; i = 2, 3$$

$$t_4(y_2 = 2, y_3 = 2, x, 3) = 1; \lambda_4 = 0.2$$

$$s_1(y_1 = 1, x, 1) = 1; \mu_1 = 1.0$$

$$s_2(y_i = 2, x, i) = 1; \mu_2 = 0.5; i = 1, 2, 3$$

$$s_3(y_i = 1, x, i) = 1; \mu_1 = 0.8; i = 2, 3$$

$$\delta_3(l) = \arg \max_{1 \leq j \leq 2} \left(\delta_2(j) + \sum_{k=1}^K w_k f_k(y_2 = j, y_3 = l, x, 3) \right)$$

$$\delta_3(1) = \arg \max_{1 \leq j \leq 2} (3.4 + (0 + 0.8 + 0.8), 3.5 + (1.0 + 0.5 + 0.8)) = 5.8$$

$$\delta_3(2) = \arg \max_{1 \leq j \leq 2} (3.4 + (1.0 + 0.8 + 0.5), 3.5 + (0.2 + 0.5 + 0.5)) = 5.7$$

CRF

⌚ 反向回溯:

$$\delta_1(1) = 1.0 \quad \delta_1(2) = 0.5$$


$$\delta_2(1) = \arg \max_{1 \leq j \leq 2} (1.0 + (0.6 + 1.0 + 0.8), 0.8 + (1.0 + 0.5 + 0.8)) = 3.4$$

$$\delta_2(2) = \arg \max_{1 \leq j \leq 2} (1.0 + (1.0 + 1.0 + 0.5), 0.8 + (0 + 0.5 + 0.5)) = 3.5$$

$$\delta_3(1) = \arg \max_{1 \leq j \leq 2} (3.4 + (0 + 0.8 + 0.8), 3.5 + (1.0 + 0.5 + 0.8)) = 5.8$$

$$\delta_3(2) = \arg \max_{1 \leq j \leq 2} (3.4 + (1.0 + 0.8 + 0.5), 3.5 + (0.2 + 0.5 + 0.5)) = 5.7$$

CRF



最有可能的序列为:1,2,1; 也就是名词、动词、名词

CRF

⌚ CRF和HMM的主要区别:

- ⌚ HMM优化的是求解 $p(x,y)$ 联合概率, CRF优化的是求解 $p(y|x)$ 条件概率;
- ⌚ HMM中有向无环图, CRF中是无向图;
- ⌚ HMM中是上一个时刻影响下一个时刻的状态, CRF中是所有时刻的输入均影响当前时刻的状态值。

CRF

⌚ CRF应用场景：

⌚ 中文分词

⌚ 词性标注

⌚ 命名实体识别

⌚ 语义角色标记

⌚ 事件提取

⌚ 等等.....

THANKS!