



六、Attention 结构

MHA



MQA

GQA



FlashAttention

论文参考: <https://papers.cool/arxiv/2205.14135>

<https://avoid.overfit.cn/post/9d812b7a909e49e6ad4fb115cc25cdc1>

<https://zhuanlan.zhihu.com/p/663932651>

<https://zhuanlan.zhihu.com/p/670085985>

PageAttention

vLLM 内部的 Attention 计算优化, 类似操作系统: 构建了一个虚拟显存管理